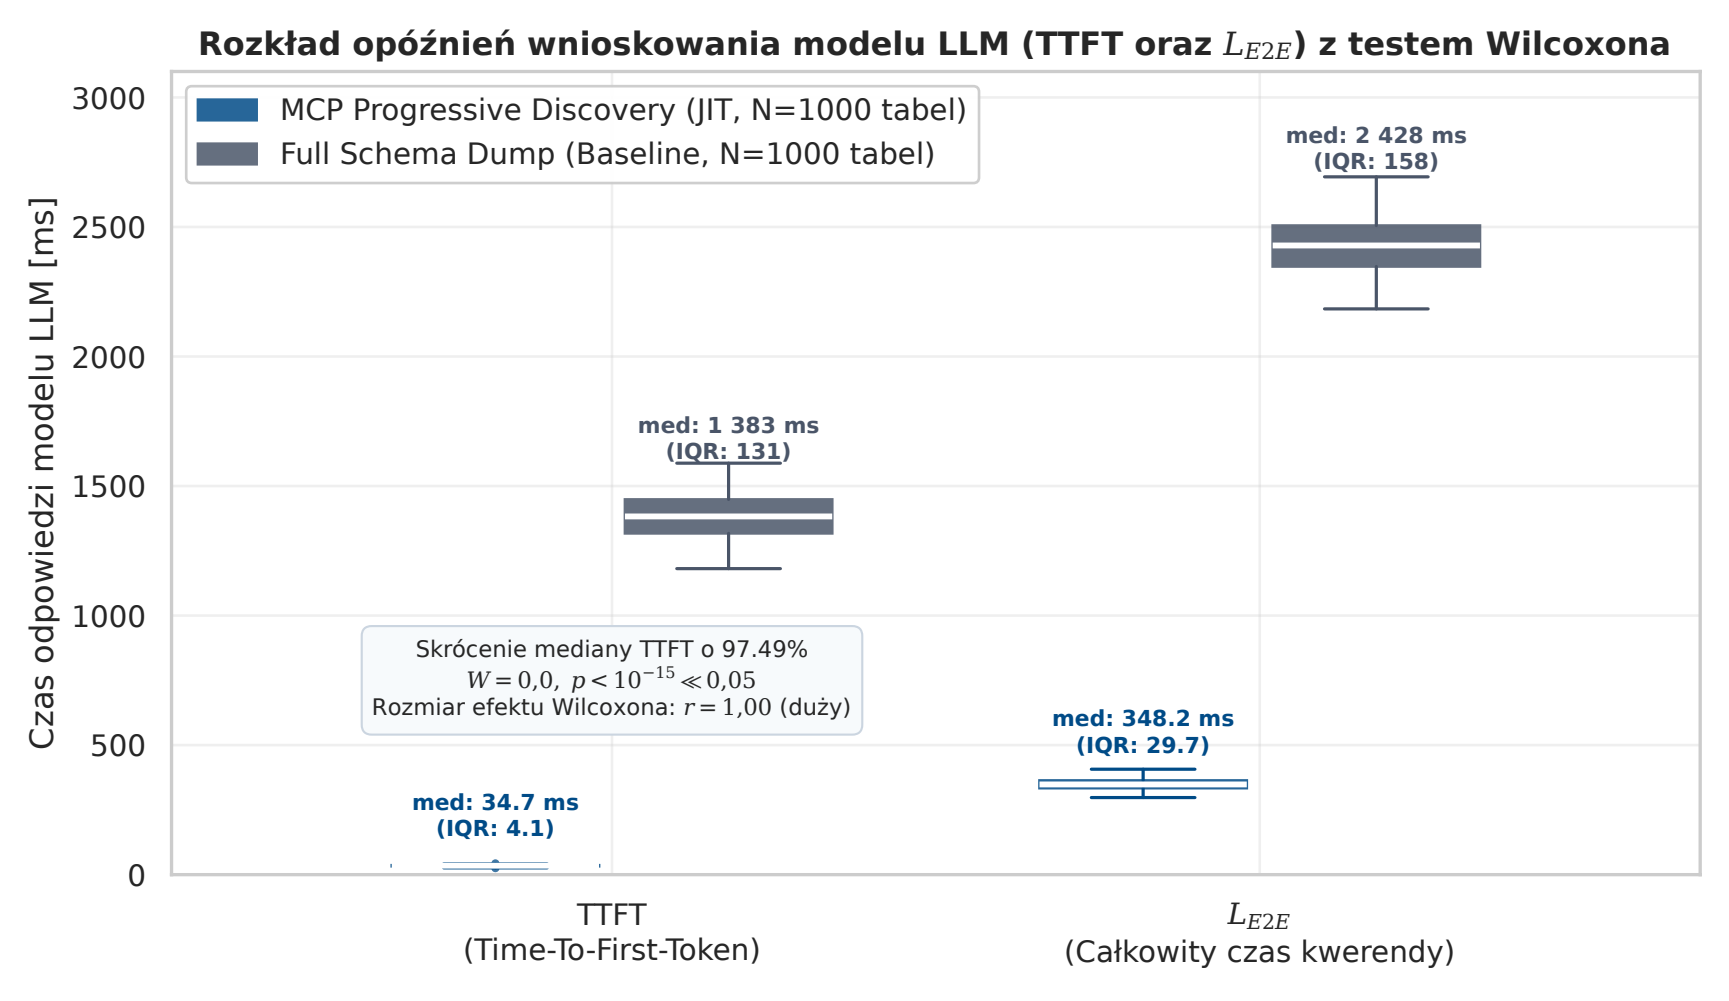
Rozkład opóźnień wnioskowania modelu LLM (TTFT oraz L_{E2E}) z testem Wilcoxona
MCP Progressive Discovery (JIT, N=1000 tabel)
Full Schema Dump (Baseline, N=1000 tabel)
Czas odpowiedzi modelu LLM [ms]
3000
2500
2000
1500
1000
500
0
med: 2 428 ms
(IQR: 158)
med: 1 383 ms
(IQR: 131)
Skrócenie mediany TTFT o 97.49%
$W = 0{,}0,\ p < 10^{-15} \ll 0{,}05$
Rozmiar efektu Wilcoxona: $r = 1{,}00$ (duży)
med: 348.2 ms
(IQR: 29.7)
med: 34.7 ms
(IQR: 4.1)
TTFT
(Time-To-First-Token)
L_{E2E}
(Całkowity czas kwerendy)