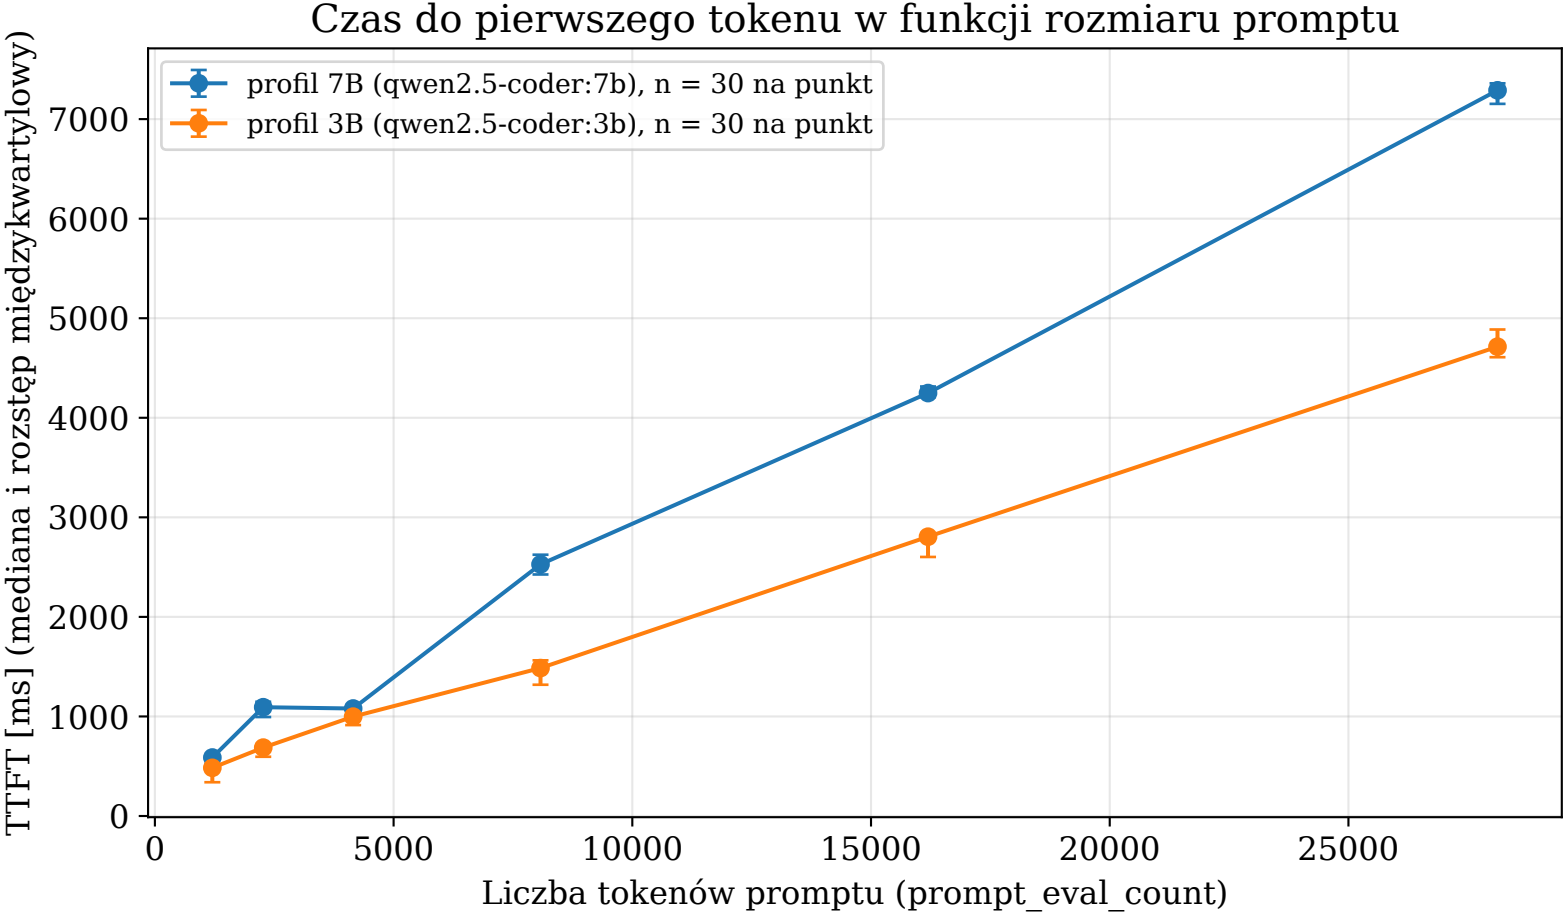
Czas do pierwszego tokenu w funkcji rozmiaru promptu
profil 7B (qwen2.5-coder:7b), n = 30 na punkt
profil 3B (qwen2.5-coder:3b), n = 30 na punkt
TTFT [ms] (mediana i rozstęp międzykwartylowy)
0
1000
2000
3000
4000
5000
6000
7000
0
5000
10000
15000
20000
25000
Liczba tokenów promptu (prompt_eval_count)