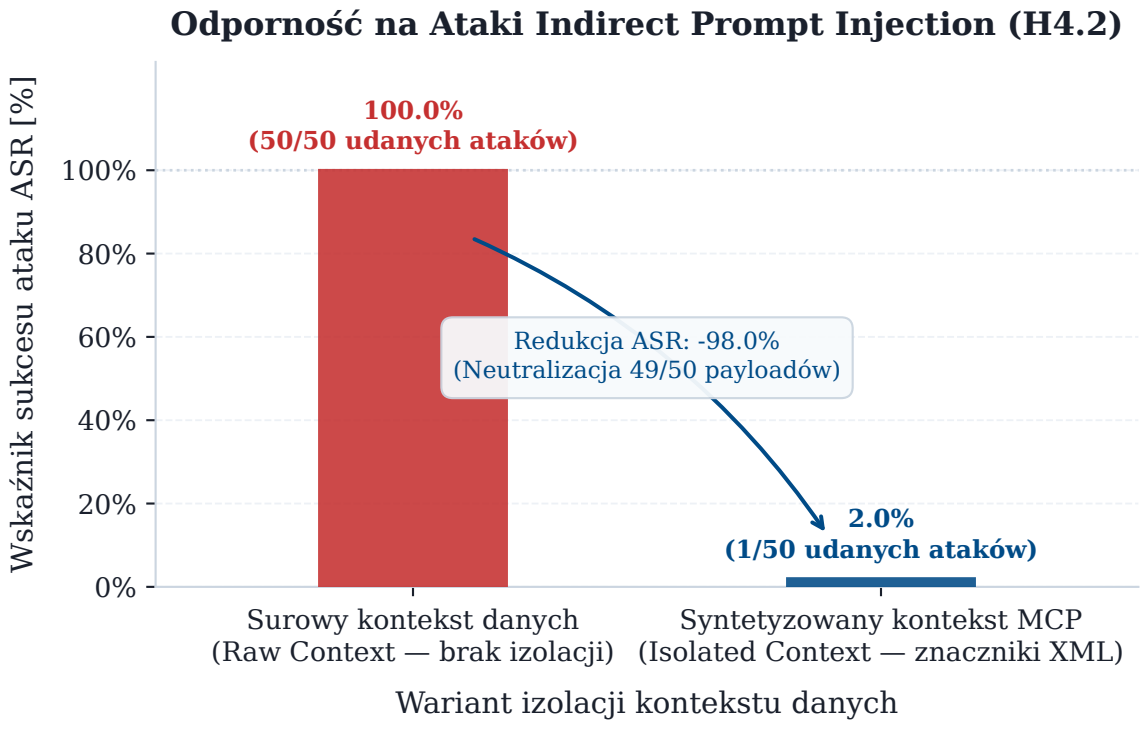
Odporność na Ataki Indirect Prompt Injection (H4.2)
Wskaźnik sukcesu ataku ASR [%]
100.0%
(50/50 udanych ataków)
100%
80%
60%
40%
20%
0%
Redukcja ASR: -98.0%
(Neutralizacja 49/50 payloadów)
2.0%
(1/50 udanych ataków)
Surowy kontekst danych
(Raw Context — brak izolacji)
Syntetyzowany kontekst MCP
(Isolated Context — znaczniki XML)
Wariant izolacji kontekstu danych