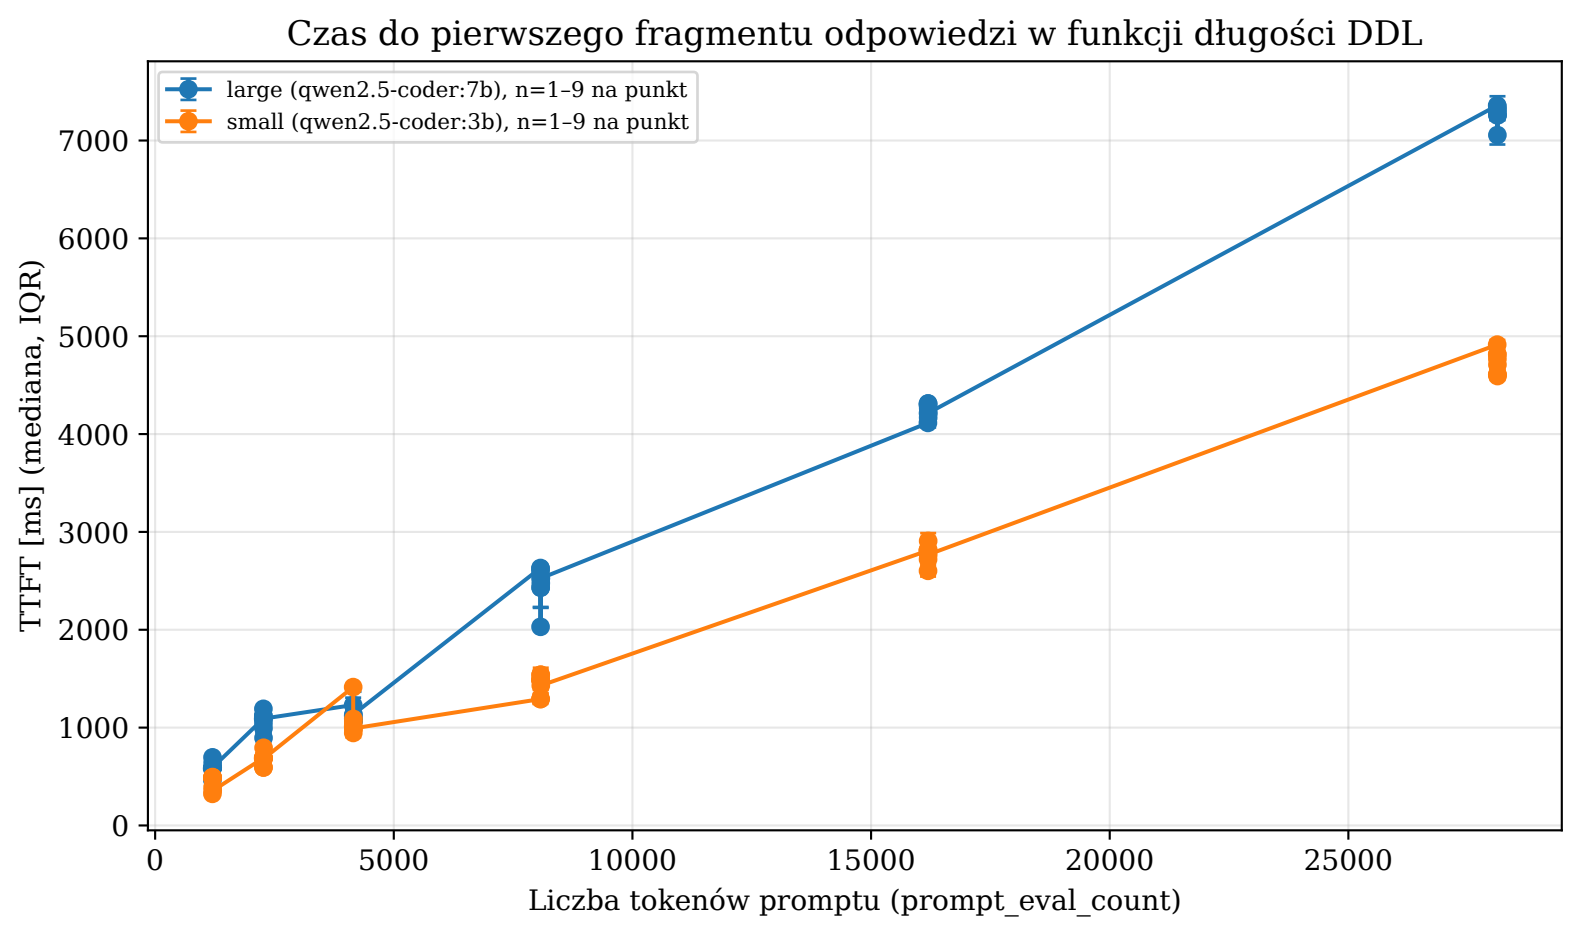
Czas do pierwszego fragmentu odpowiedzi w funkcji długości DDL
large (qwen2.5-coder:7b), n=1–9 na punkt
small (qwen2.5-coder:3b), n=1–9 na punkt
TTFT [ms] (mediana, IQR)
Liczba tokenów promptu (prompt_eval_count)
0
1000
2000
3000
4000
5000
6000
7000
0
5000
10000
15000
20000
25000